

TRAVAUX PRATIQUES — STATISTIQUES ET ANALYSE DE DONNÉES

Étude de cas appliquée — Statistique descriptive et Classification (supervisée et non supervisée)

MODALITÉS DE RÉALISATION ET DE RENDU

- Travail en groupe de 10 étudiants.
- Chaque groupe CHOISIT UN SEUL des cinq thèmes proposés dans ce document (Thème A, B, C, D ou E). Deux groupes peuvent choisir le même thème : cela ne pose aucun problème.
- Les données utilisées sont générées par chaque groupe à partir du nom de son chef de groupe (voir Annexe — Génération des données personnalisées). Toute correspondance exacte de résultats numériques entre deux rendus sera considérée comme un cas de fraude et entraînera l'invalidation des deux rendus.
- Le rendu comporte deux documents : (1) l'application développée, et (2) un rapport rédigé. Conception entièrement à la charge du groupe : structure des données, organisation du code, choix des représentations — rien n'est imposé au-delà du thème et du mécanisme de génération.
- Les deux documents sont déposés dans un seul dossier nommé INF232_TP_GROUPEXX, avec XX le numéro de votre groupe, en utilisant le formulaire dédié au TP.
- Le lien de dépôt se fermera automatiquement ce **Dimanche 5 juillet à 23h59**. Aucun dépôt ne sera accepté après cette heure.
- présentation orale aléatoire le **Lundi 6 juillet** : 2 à 3 membres tirés au sort par groupe, interrogés sur n'importe quelle partie du travail rendu, y compris des parties traitées par d'autres membres.

Langage / outil de réalisation : au choix du groupe. Le choix doit être justifié en une phrase dans le rapport

. ANNEXE — GÉNÉRATION DES DONNÉES PERSONNALISÉES DU GROUPE

Cette étape est obligatoire et conditionne l'ensemble du TP. Toutes les données utilisées dans votre thème doivent provenir d'un générateur dérivé du nom de votre chef de groupe, conçu et implémenté par vous-même selon le principe ci-dessous.

Principe à respecter (la conception détaillée vous revient)

Vous devez concevoir, documenter et implémenter une fonction qui transforme le nom complet de votre chef de groupe (nom et prénom, sans accents ni espaces) en un nombre entier reproductible, appelé graine du groupe. Cette graine doit ensuite alimenter un générateur de nombres pseudo-aléatoires (au choix : un générateur standard de votre langage initialisé avec cette graine, ou un mécanisme de votre conception) qui produira l'ensemble des données nécessaires à votre thème.

Exemple illustratif (à titre d'exemple uniquement, ne pas réutiliser tel quel) : si les membres du groupe se nomme AVOCAT BEURRE Pierre Le Boulange, la chaîne de caractères à transformer serait "PIERRELEBOULANGEAVOCATBEURRE" (prénoms et nom concaténés, en majuscules, sans espaces ni accents). C'est à vous de concevoir la fonction qui transforme cette chaîne en graine numérique, puis le générateur qui en dérive vos données.

Aucune structure de données, aucun format de tableau, aucun intervalle de valeurs n'est imposé par ce document : c'est à votre groupe de déterminer, en fonction du thème choisi et des questions posées,

quelles données générer, en quelle quantité, sous quelle forme et avec quelles bornes plausibles pour le contexte étudié. Ce choix de conception fait partie intégrante du travail évalué.

Contraintes non négociables :

- Le processus de génération doit être déterministe autrement dit, relancer votre programme avec le même nom de chef de groupe doit toujours produire exactement les mêmes données.
- Deux noms différents doivent, dans l'immense majorité des cas, produire des données différentes.
- La taille de l'échantillon généré doit être suffisante pour rendre les méthodes statistiques mobilisées pertinentes (ordre de grandeur à justifier vous-même selon le thème et la méthode retenue. Il n'y a pas de nombre unique attendu).

ATTENTION !!!

La conception du mécanisme de génération fait partie du travail noté. Le rapport doit inclure : la description précise de votre algorithme de génération (avec justification des choix), le code correspondant, la graine obtenue pour votre groupe, et un extrait représentatif des données produites, pour permettre la vérification de la cohérence de l'ensemble du jeu de données à partir du seul nom du chef de groupe.

Chaque thème ci-dessous est un cas d'usage complet, à traiter dans son intégralité. Aucune méthode statistique n'est nommée dans les énoncés : c'est au groupe d'identifier, de choisir et de justifier les outils du cours (statistique univariée, bivariée, classification supervisée, classification non supervisée) qui permettent de répondre à chaque partie du cas. Un même thème doit mobiliser, à un moment ou un autre de son traitement complet, les quatre grands blocs de notions vus en cours.

THEME A : Service de santé universitaire

Contexte

Le service de santé de l'Université de MBOUDA souhaite mieux comprendre l'état de santé général des étudiants à partir d'un dépistage de routine mené sur un échantillon d'étudiants. Pour chaque étudiant dépisté, plusieurs informations sont relevées : un indicateur physiologique mesuré (au choix du groupe, à définir et justifier dans un contexte de santé étudiante plausible), une seconde mesure physiologique potentiellement liée à la première, et un résultat de dépistage classant chaque étudiant en "à risque" ou "non à risque" selon les critères du service de santé.

Le directeur du service de santé de l'Université de MBOUDA vous transmet ce jeu de données et vous pose quatre questions, dans l'ordre où il les a notées dans son carnet :

Question 1 — « Avant toute chose, dites-moi simplement comment se répartit, dans mon échantillon, le premier indicateur physiologique que vous avez mesuré : quelles sont les valeurs typiques, y a-t-il des étudiants dont la mesure sort vraiment du lot, et comment puis-je présenter cela simplement à mon équipe médicale qui n'est pas formée en statistique ? »

Question 2 — « Mon équipe pense que les deux indicateurs physiologiques que vous avez mesurés évoluent ensemble chez nos étudiants. Est-ce vrai dans les données que vous avez recueillies ? Et si c'est le cas, pourrait-on, à l'avenir, ne mesurer qu'un seul des deux indicateurs et estimer l'autre, pour gagner du temps lors des campagnes de dépistage de masse ? Dites-moi aussi à partir de quand une telle estimation deviendrait dangereuse à utiliser. »

Question 3 — « On me dit qu'il existe peut-être, parmi mes étudiants dépistés, des groupes naturels de profils de santé différents, qu'on n'aurait pas encore identifiés faute d'avoir cherché. Pouvez-vous me dire combien de profils distincts se dégagent réellement de mes données, et décrire chacun de ces profils en des termes que je peux comprendre ? »

Question 4 — « Pour les campagnes futures, j'aimerais pouvoir prédire automatiquement, dès le dépistage d'un nouvel étudiant et sans attendre tous les résultats d'analyse, s'il sera probablement classé "à risque" ou non, uniquement à partir de ses deux mesures physiologiques. Est-ce possible avec ce que vous avez recueilli ? Quelle confiance puis-je accorder à une telle prédiction automatique, et que se passerait-il si je me trompais en l'utilisant pour de vrais étudiants ? »

THEME B : Plateforme de mise en relation freelance/client

Contexte

Une jeune entreprise camerounaise gère une plateforme web qui met en relation des freelances (développeurs, designers, rédacteurs) avec des clients. Pour chaque freelance inscrit, la plateforme dispose d'un historique : une mesure de performance (au choix du groupe, à définir et justifier dans ce contexte), une mesure d'activité ou de tarification potentiellement liée à la première, et une étiquette indiquant si le freelance a été classé "profil premium" ou "profil standard" par l'équipe commerciale lors d'une précédente campagne.

La fondatrice de la plateforme, qui n'a aucune formation en statistique, vous transmet ces données et vous pose quatre questions, dans l'ordre où elle les a écrites dans un message vocal :

Question 1 — « Je voudrais d'abord comprendre, sur l'ensemble de mes freelances, comment se répartit leur niveau de performance. Y a-t-il des cas vraiment extrêmes, des freelances très en dehors de la norme ? Et comment je pourrais résumer ça en une ou deux phrases simples pour mon prochain comité d'investisseurs ? »

Question 2 — « Je soupçonne qu'il existe un lien entre la performance d'un freelance et son niveau d'activité ou de tarification sur la plateforme. Pouvez-vous vérifier cela dans mes données ? Et si le lien existe, pourrait-on utiliser le niveau d'activité d'un nouveau freelance pour anticiper sa performance avant même qu'il ait des missions terminées ? Jusqu'à quel point une telle anticipation reste-t-elle raisonnable ? »

Question 3 — « Mon équipe commerciale a classé les freelances en "premium" et "standard" un peu au feeling, sans méthode claire. Indépendamment de cette étiquette, est-ce que mes données elles-mêmes révèlent naturellement des groupes de freelances aux profils proches ? Combien de groupes distincts ressortent, et comment les décririez-vous à mon équipe ? »

Question 4 — « Pour automatiser une partie du travail commercial, j'aimerais qu'un nouveau freelance qui s'inscrit soit automatiquement orienté vers "premium" ou "standard" dès l'inscription, à partir de ses deux indicateurs mesurables. Est-ce raisonnable avec ce que j'ai comme données ? Quelle serait la fiabilité réelle d'un tel système, et quel risque commercial je prendrais à m'y fier aveuglément ? »

THEME C: Coopération Agricole

Contexte

Une coopérative agricole regroupant plusieurs exploitations dans une région du Cameroun souhaite mieux piloter sa production. Pour chaque exploitation membre, la coopérative dispose d'un historique de campagne : une mesure liée à la production (au choix du groupe, à définir et justifier dans ce contexte agricole), une seconde mesure potentiellement liée à la première (par exemple une ressource utilisée ou une condition d'exploitation), et un classement attribué par les techniciens agricoles : exploitation "performante" ou "à accompagner".

Le responsable technique de la coopérative vous transmet ce jeu de données et vous pose quatre questions, dans l'ordre de la réunion de restitution :

Question 1 — « Je voudrais d'abord une vue claire de la dispersion de la production de mes exploitations cette saison. Quelles exploitations s'écartent franchement de la tendance générale, dans un sens ou dans l'autre ? Et comment résumer cela simplement pour la prochaine assemblée générale des membres, qui ne sont pas du tout statisticiens ? »

Question 2 — « On pense, à la coopérative, que la production d'une exploitation dépend fortement de la seconde mesure que vous avez recueillie. Est-ce confirmé par vos données ? Si oui, pourrait-on, pour les exploitations qui n'ont pas encore communiqué leurs résultats de production de la saison, estimer celle-ci à partir de cette seconde mesure seule ? Dans quelles limites une telle estimation resterait-elle fiable ? »

Question 3 — « Indépendamment du classement "performante / à accompagner" déjà fait par nos techniciens, est-ce que les données elles-mêmes font ressortir des groupes naturels d'exploitations aux profils proches ? Combien de profils-types distincts identifiez-vous, et comment les caractériseriez-vous pour orienter nos futures actions d'accompagnement ? »

Question 4 — « Pour la prochaine campagne, j'aimerais pouvoir anticiper dès le départ, à partir des deux mesures disponibles en début de saison, si une exploitation risque d'être classée "à accompagner" en fin de saison, afin d'intervenir plus tôt. Est-ce possible avec vos données actuelles ? Quelle confiance puis-je accorder à une telle anticipation, et quel est le risque si elle se trompe pour une exploitation réellement fragile ? »

THEME D : Etablissement scolaire secondaire

Contexte

La direction d'un établissement scolaire secondaire souhaite mieux comprendre les performances et profils de ses élèves de terminale à partir des résultats d'une évaluation interne. Pour chaque élève évalué, l'établissement dispose : d'un résultat à une évaluation (au choix du groupe, à définir et justifier dans ce contexte scolaire), d'une seconde mesure potentiellement liée à la première (par exemple liée au travail personnel ou à l'assiduité), et d'une orientation déjà recommandée par le conseil de classe : "filiale scientifique" ou "filiale littéraire".

Le proviseur, qui ne maîtrise pas la statistique, vous transmet ces données et vous pose quatre questions, dans l'ordre de leur entretien avec vous :

Question 1 — « Avant de prendre toute décision, je veux comprendre comment se répartissent les résultats de mes élèves à cette évaluation. Y a-t-il des élèves dont le résultat sort vraiment de l'ordinaire, dans un sens comme dans l'autre ? Et comment puis-je présenter cela simplement au conseil pédagogique, qui n'est pas formé en statistique ? »

Question 2 — « Certains professeurs pensent que le résultat à cette évaluation est fortement lié à la seconde mesure que vous avez recueillie. Est-ce vérifié dans mes données ? Si oui, pourrait-on, pour les élèves qui n'ont pas encore passé l'évaluation, anticiper leur résultat probable à partir de cette seconde mesure ? À partir de quel point une telle anticipation deviendrait-elle trop incertaine pour être utilisée sérieusement ? »

Question 3 — « Indépendamment de l'orientation déjà recommandée par le conseil de classe, est-ce que mes données font naturellement apparaître des groupes d'élèves aux profils proches ? Combien de profils distincts identifiez-vous réellement, et comment les décrieriez-vous pour aider le conseil pédagogique à mieux accompagner chaque groupe ? »

Question 4 — « Pour les prochaines années, j'aimerais qu'un système puisse suggérer automatiquement une orientation ("scientifique" ou "littéraire") pour un nouvel élève, uniquement à partir de ses deux mesures disponibles, avant même la délibération du conseil de classe. Est-ce raisonnable avec mes données actuelles ? Quelle confiance puis-je accorder à une telle suggestion automatique, et quel risque pédagogique prendrais-je à m'y fier sans recul ? »

THEME A : Lutte contre le paludisme au Cameroun

Contexte

Un programme national de lutte contre le paludisme souhaite explorer comment des outils de machine learning pourraient aider les centres de santé à orienter plus rapidement chaque patient vers le traitement antipaludique le plus adapté à son profil, plutôt que de suivre un protocole identique pour tous. Pour chaque patient pris en charge dans le cadre d'une étude pilote, le programme dispose : d'une mesure clinique relevée à l'admission (au choix du groupe, à définir et justifier dans ce contexte médical), d'une seconde mesure clinique ou biologique potentiellement liée à la première, et du traitement effectivement administré par les médecins, classé en deux grandes catégories de protocole thérapeutique.

La coordinatrice du programme national, qui n'est pas data-scientist, vous transmet ces données et vous pose quatre questions, dans l'ordre où elle les a listées avant votre rencontre :

Question 1 — « Avant toute chose, je veux comprendre comment se répartit, dans notre échantillon de patients, la première mesure clinique relevée à l'admission. Y a-t-il des patients dont la mesure est vraiment hors-norme par rapport aux autres, et que cela pourrait signifier cliniquement ? Comment puis-je présenter cela simplement à une équipe de terrain qui n'est pas formée en statistique ? »

Question 2 — « Certains médecins du programme pensent que les deux mesures cliniques que vous avez recueillies évoluent ensemble chez nos patients. Est-ce vérifié dans nos données ? Si c'est le cas, pourrait-on, dans des centres de santé isolés où une seule des deux mesures est facilement réalisable, estimer la seconde à partir de la première pour accélérer la prise en charge ? À partir de quel point une telle estimation deviendrait-elle dangereuse à utiliser sur un vrai patient ? »

Question 3 — « Indépendamment du traitement effectivement choisi par les médecins, est-ce que nos données font naturellement apparaître des groupes de patients aux profils cliniques proches, que le programme n'aurait pas encore identifiés comme tels ? Combien de profils-types distincts ressortent réellement de l'analyse, et comment les décririez-vous à notre équipe médicale ? »

Question 4 — « L'objectif final du programme est qu'un centre de santé puisse, dès l'admission d'un nouveau patient et à partir de ses seules mesures cliniques disponibles, recevoir une suggestion automatique du protocole thérapeutique le plus probablement adapté, avant même les résultats d'analyses complémentaires. Est-ce réalisable avec les données dont nous disposons ? Quelle confiance peut-on raisonnablement accorder à une telle suggestion automatique dans un contexte où une erreur peut avoir des conséquences graves pour le patient, et quelles précautions un centre de santé devrait-il prendre avant de s'y fier ? »

CONSIGNES COMMUNES À TOUS LES THÈMES

1. Démarche attendue

- Pour chacune des quatre questions de votre thème, vous devez : identifier vous-même la ou les notions du cours mobilisables, choisir et justifier la méthode retenue (et pas une autre), l'appliquer sur vos propres données générées, présenter le résultat de façon rigoureuse (calculs,

graphiques pertinents), puis répondre à la question telle qu'elle est posée, dans un langage compréhensible par le commanditaire fictif du thème (qui n'est pas statisticien).

- Aucune des quatre questions ne se limite à un seul calcul isolé : chacune attend une démarche complète, une interprétation, et une discussion des limites de la réponse apportée.
- Le rapport doit également contenir, pour chaque question, une discussion explicite de ce qui pourrait rendre la réponse fragile ou trompeuse (données insuffisantes, valeurs atypiques, limites de la méthode choisie, etc.).

2. Ce qui est volontairement laissé à votre charge

- Le choix du ou des indicateurs physiologiques, commerciaux, agricoles ou scolaires concrets que vous mesurez (vous devez les nommer et les justifier dans le contexte du thème choisi).
- Le nombre d'individus à générer et les bornes plausibles des valeurs, cohérents avec le contexte du thème et avec les méthodes que vous choisirez d'appliquer.
- La structure de vos données et l'organisation de votre code : rien n'est imposé au-delà du mécanisme de génération décrit en Annexe.
- Le choix des méthodes statistiques exactes mobilisées pour chaque question : aucune n'est nommée dans cet énoncé.

3. Exigence transversale

Sur l'ensemble des quatre questions de votre thème, votre travail doit, au total, avoir mobilisé : une analyse de série statistique à une seule variable, une analyse de relation entre deux variables, une démarche de classification non supervisée (recherche de groupes sans étiquette préalable), et une démarche de classification supervisée (prédiction d'une étiquette connue à partir d'autres mesures). Libre à vous de répartir ces quatre démarches entre les quatre questions comme la logique de votre thème vous semble l'exiger — ce découpage fait partie de votre travail de conception.

MODALITÉ DE DÉPÔT — RAPPEL FINAL

1. Composition du dossier à déposer

- Un document "**Application**" : code source complet de l'application, accompagné des données générées et d'un mode d'emploi pour l'exécuter (3-4 lignes suffisent).
- Un document "**Rapport**" : indication claire du thème choisi (A, B, C, D ou E), description et justification du mécanisme de génération de données (Annexe), puis réponses complètes et illustrées aux quatre questions du thème.

2. Nommage et organisation

- Le dossier complet doit être nommé uniquement avec le nom INF232_TP_GROUPEXX avec XX le numéro de votre groupe..
- Ce dossier est déposé dans le Formulaire Google dédié au TP.

3. Délai

- Le lien de dépôt sera fermé automatiquement le Dimanche 5 juillet à 23h59. Passé ce délai, aucun dossier ne pourra être ajouté.

4. présentation

- La présentation orale aléatoire aura lieu le Lundi 6 juillet 2026. Présence obligatoire de tous les membres du groupe.