

The University of Yaoundé I

Faculté des Sciences

Département d'informatique
computer



Université de Yaoundé I

Faculty of Sciences

Department of

TP INF 232 : STATISTIQUES ET ANALYSE DE DONNEES

Thème D : Etablissement scolaire secondaire

Analyse statistique des performances et profils d'élèves de terminale

Groupe : INF232_TP_GROUPE31

Chef de groupe : VAMI NEGUEM YVO FREED

Langage : Python 3 — NumPy, Pandas, SciPy, Matplotlib, Scikit-learn

Supervisé par : Dr NZEKON armel

Année académique : 2025/2026

Membres du groupe :

- VAMI NEGUEM YVO FREED 24F2658 (chef de groupe)
- OUMAROU MVONGO CALEB ISRAEL 24G2771
- SOHMU BELTUS KOHTEM 24F2635
- LEMATSOP MARIE JOSEPHINE 24G2300
- MINYEMECK BAMA BERNARD ESTIN 24G2534
- NGOUNGOURE NCHANKOU FATIMA 24F2967
- TIKI EKOBO NGJILA SAMUEL JORDAN 24G2647
- BAKWO NKEM BERNARDIN ULRICH 23V2277
- NOUBIWO FOKOU CAROLE INES 24F2554
- TCHEUTCHOUA LENCHE RAISSA 24F2440

TABLE DES MATIERES

1. Génération des données
 - 1.1 De la chaîne de caractères à la graine numérique
 - 1.2 Les données produites
2. Question 1 : Comment se répartissent les notes ?
 - 2.1 Résultats chiffrés
 - 2.2 Élèves atypiques
 - 2.3 Limites
3. Question 2 : L'assiduité permet-elle d'anticiper la note ?
 - 3.1 Normalité et corrélation
 - 3.2 Régression linéaire
 - 3.3 Fiabilité de l'estimation
 - 3.4 Contre-exemples
4. Question 3 : Y a-t-il des profils types d'élèves ?
 - 4.1 Détermination du nombre de groupes
 - 4.2 Portrait des profils
 - 4.3 Cohérence avec l'analyse univariée
5. Question 4 : Peut-on prédire l'orientation automatiquement ?
 - 5.1 Modèles comparés
 - 5.2 Performance et matrice de confusion
 - 5.3 Analyse des erreurs et préconisations
6. Synthèse : Ce que tout cela raconte

Le choix de Python et de son écosystème scientifique (NumPy, Pandas, SciPy, Scikit-learn, Matplotlib) est motivé par la présence d'outils intégrés et performants pour l'analyse de données et la modélisation statistique, garantissant également la lisibilité du code.

1. GENERATION DES DONNEES

Le mécanisme de génération est l'élément obligatoire qui garantit l'unicité et la reproductibilité des données de chaque groupe. Le point de départ est le nom complet du chef de groupe : VAMI NEGUEM YVO FREED.

1.1 De la chaîne de caractères à la graine numérique

Notre algorithme suit le principe de l'annexe du sujet : prénoms avant nom, en majuscules, sans accents ni espaces. La chaîne subit une décomposition NFD (isole les diacritiques), une suppression des accents (catégorie Unicode Mn), une mise en majuscules, un découpage en mots, puis une réorganisation où la moitié droite (prénoms) précède la moitié gauche (nom).

Processus complet :

Entrée : "VAMI NEGUEM YVO FREED"

- décomposition NFD (isole les diacritiques)
- suppression des accents (catégorie Unicode "Mn")
- mise en majuscules → "VAMI NEGUEM YVO FREED"
- découpage en mots : ["VAMI", "NEGUEM", "YVO", "FREED"]
- moitié gauche = NOM ("VAMI" + "NEGUEM")
- moitié droite = prénoms ("YVO" + "FREED")
- réorganisation : prénoms + nom
- suppression de tout caractère non alphabétique

Sortie : "YVOFREEDVAMINEGUEM"

Cette chaîne normalisée est transformée en un entier reproductible via un hachage polynomial (inspiré de `String.hashCode()` de Java) en base 31, modulo $2^{31}-1$ (nombre de Mersenne premier). La base 31 est un nombre premier historiquement validé pour le hachage de chaînes, garantissant une bonne diffusion et peu de collisions.

Code de génération de la graine :

```
from __future__ import annotations

import re
import unicodedata

_BASE = 31
_MODULUS = 2**31 - 1

def normalize_name(full_name: str) -> str:
    decomposed = unicodedata.normalize("NFD", full_name.strip())
    without_accents = "".join(
        char for char in decomposed if unicodedata.category(char) != "Mn"
    )
    upper = without_accents.upper()
    words = re.findall(r"[A-Z]+", upper)
    if len(words) < 2:
        return "".join(words)
    n = len(words) // 2
    lastname = "".join(words[:n])
    firstnames = "".join(words[n:])
    return firstnames + lastname

def name_to_seed(full_name: str) -> int:
    normalized = normalize_name(full_name)
    if not normalized:
        raise ValueError("The normalized name is empty: please check the group leader's name.")
    seed = 0
    for char in normalized:
        seed = (seed * _BASE + ord(char)) % _MODULUS
    return seed
```

Graine obtenue : 1976473691.

1.2 Les données produites

Une fois la graine en main, nous initialisons un générateur pseudo-aléatoire NumPy (default_rng(seed)) et générons 150 profils d'élèves selon une loi normale bivariée. Le choix d'une loi normale bivariée se justifie par le fait que, dans une population scolaire homogène, les notes d'évaluation et les taux d'assiduité tendent à se répartir de manière symétrique autour d'une valeur moyenne centrale. Les paramètres ont été choisis pour refléter une situation scolaire réaliste :

Variable	Description	Plage
average_grade	Moyenne générale sur 20 (évaluation interne)	[4,0 ; 19,5]
attendance	Taux de présence annuel (pourcentage)	[55 ; 100]
major	Orientation conseillée par le conseil de classe	scientific / literary

Le tirage bivarié introduit une corrélation volontaire de $\rho = 0,58$ entre la note et l'assiduité, ce qui reproduit une tendance naturelle (les élèves présents réussissent en

moyenne mieux) sans que le lien soit mécanique. La variable major est attribuée via un score logistique bruité, garantissant un chevauchement réaliste entre les deux filières.

Extrait des données générées (5 premiers élèves) :

student_id	average_grade	attendance	major
E001	12.97	100.0	literary
E002	9.52	75.4	literary
E003	10.4	73.5	literary
E004	12.65	89.9	literary
E005	9.3	69.3	literary

Code de génération du jeu de données :

```
from __future__ import annotations
from pathlib import Path
import numpy as np
import pandas as pd
import yaml

_CONFIG_PATH = Path("config/config.yaml")
def _load_config(path: Path = _CONFIG_PATH) -> dict:
    with open(path, encoding="utf-8") as f:
        return yaml.safe_load(f)
def _build_covariance_matrix(cfg: dict) -> np.ndarray:
    rho = cfg["generation"]["correlation_note_assiduite"]
    std_note = cfg["generation"]["note"]["std"]
    std_assid = cfg["generation"]["assiduite"]["std"]
    cov = rho * std_note * std_assid
    return np.array([[std_note**2, cov], [cov, std_assid**2]])
def generate_dataset(seed: int) -> pd.DataFrame:
    """Generates the full dataset from an integer seed."""
    cfg = _load_config()
    gen_cfg = cfg["generation"]
    ori_cfg = cfg["orientation"]
    rng = np.random.default_rng(seed)
    mean_vector = np.array([gen_cfg["note"]["mean"], gen_cfg["assiduite"]["mean"]])
    cov_matrix = _build_covariance_matrix(cfg)
    samples = rng.multivariate_normal(mean_vector, cov_matrix, size=gen_cfg["n_eleves"])
    notes = np.clip(samples[:, 0], gen_cfg["note"]["min"], gen_cfg["note"]["max"])
    assiduites = np.clip(samples[:, 1], gen_cfg["assiduite"]["min"], gen_cfg["assiduite"]["max"])
    noise = rng.normal(0.0, ori_cfg["bruit_std"], size=len(notes))
    score = ori_cfg["coef_note"] * notes + ori_cfg["coef_assiduite"] * assiduites + noise
    majors = np.where(score >= ori_cfg["seuil"], "scientific", "literary")
    return pd.DataFrame({
        "student_id": [f"E{i:03d}" for i in range(1, gen_cfg["n_eleves"] + 1)],
        "average_grade": np.round(notes, 2),
        "attendance": np.round(assiduites, 1),
        "major": majors,
    })
```

150 élèves est un effectif suffisant pour appliquer des méthodes statistiques (la règle empirique veut au moins 30 observations par groupe pour le théorème central limite), tout en restant plausible pour un lycée de taille moyenne.

2. QUESTION 1 COMMENT SE REPARTISSENT LES NOTES ?

Le proviseur veut un résumé clair de la distribution des notes, savoir s'il y a des cas extrêmes, et pouvoir le présenter simplement à son conseil pédagogique. Nous avons mobilisé deux familles d'outils : les indicateurs classiques de tendance centrale et de dispersion, et deux méthodes de détection des valeurs atypiques (IQR et Z-score).

Choix et justification de la méthode :

- Tendance centrale et dispersion : Pour résumer les notes, nous utilisons conjointement la moyenne (sensible aux extrêmes) et la médiane (robuste). Leur comparaison permet d'évaluer la symétrie de la distribution. Nous complétons par l'écart-type pour la dispersion globale, et par les quartiles et l'écart interquartile (IQR) pour mesurer l'étalement du cœur de la distribution.
- Détection des élèves atypiques : Nous utilisons la méthode du Z-score (paramétrique, seuil $|Z| > 2$), car nos données suivent une loi normale sous-jacente. Pour éviter le phénomène de masquage et ne pas dépendre d'une hypothèse de distribution, nous la complétons par la méthode robuste de l'IQR (méthode de Tukey, $k = 1,5$), non paramétrique.

2.1 Résultats chiffrés

Indicateur	Valeur
Effectif	150 élèves
Moyenne	11.76 /20
Médiane	11.61 /20
Écart-type	2.88
Étendue	[4.0 ; 19.5]
Q1 – Q3	[9.85 ; 13.67]
Écart interquartile (IQR)	3.82

La distribution est relativement symétrique (moyenne et médiane proches), ce qui est co-hérent avec une génération gaussienne.




Figure 1 : Histogramme de la distribution des notes moyennes

2.2 Élèves atypiques

Deux méthodes convergent vers les mêmes profils hors norme :

IQR (méthode de Tukey, $k = 1,5$) : 3 élèves détectés, avec des notes sous 4.11 ou au-dessus de 19.4.

Z-score (seuil $|Z| > 2$) : 8 élèves détectés.

Élève	Note	Z-score	Type
E023	4.0	-2.7	low
E049	19.5	2.69	high
E067	4.0	-2.7	low
E095	5.34	-2.23	low
E097	5.98	-2.01	low
E125	17.64	2.04	high
E132	17.82	2.11	high
E136	17.71	2.07	high

Ces résultats ne sortent pas de nulle part : les quatre meilleurs élèves sont tous en filière scientifique, les quatre plus faibles en littéraire. C'est le premier indice que note et orientation sont liées.




Figure 2 : Boxplot des notes avec mise en évidence des valeurs atypiques (Z-score)

2.3 Limites

Le Z-score suppose que les notes suivent une loi normale c'est approximativement vrai ici mais pas parfait. L'IQR avec $k = 1,5$ n'a détecté que 3 élèves car nos bornes d'édition $[4,0 ; 19,5]$ sont naturellement resserrées. Ces méthodes sont des signaux d'alerte, pas des diagnostics absolus.

Ce qu'il faut retenir : La grande majorité des élèves (94 %) se situe dans une zone normale entre 4 et 19,5/20. Les cas extrêmes existent mais restent rares et cohérents avec leur filière.

3. QUESTION 2 L'ASSIDUITE PERMET-ELLE D'ANTICIPER LA NOTE ?

Le proviseur aimerait savoir si, à l'avenir, on pourrait estimer la note d'un élève à partir de sa seule assiduité. Avant de répondre, vérifions déjà si le lien existe.

Choix et justification de la méthode :

- Test de normalité : Nous appliquons le test de Shapiro-Wilk, reconnu comme le test le plus puissant et adapté pour valider l'hypothèse de normalité sur des échantillons de taille modérée ($n=150$).
- Corrélation : L'assiduité n'étant pas distribuée normalement ($p < 0,001$), le coefficient de Pearson (paramétrique) risquerait d'être biaisé. Nous justifions donc le choix du coefficient de Spearman (non paramétrique), qui évalue la relation monotone en se basant sur les rangs.
- Modélisation : Nous retenons la régression linéaire simple par la méthode des moindres carrés (OLS). Elle offre une équation explicite et facilement interprétable ($y = ax + b$) pour anticiper la note, tout en permettant le calcul d'intervalles de prédiction pour quantifier rigoureusement l'incertitude.

3.1 Normalité d'abord

Nous avons soumis les deux variables au test de Shapiro-Wilk :

Variable	Statistique W	p-value	Conclusion
attendance	$W = 0.941$	$p < 0.001$	non normale
average_grade	$W = 0.994$	$p = 0.7953$	normale

Cette non-normalité de l'assiduité nous oriente naturellement vers le coefficient de Spearman (qui n'exige pas de normalité) comme mesure principale, en complément de Pearson.

3.2 Corrélation : un lien modéré à fort

Le coefficient de Spearman vaut $\rho = 0.6425$ ($p < 0,001$). C'est un lien positif et statistiquement très significatif : en moyenne, plus un élève est assidu, meilleure est sa note.

Méthode	Coefficient	p-value
Pearson (r)	0.6305	$p < 0.001$
Spearman (ρ)	0.6425	$p < 0.001$

3.3 Régression : peut-on estimer la note ?

Équation de la droite de régression : $\text{grade} = 0.1832 \times \text{attendance} + -4.2670$

Indicateur	Valeur
R^2	39.7%
RMSE	2.241 points

Si le proviseur veut estimer la note d'un élève à 80 % d'assiduité : 10.39/20 en moyenne. Mais l'intervalle de prédiction à 95 % donne une fourchette de près de 9 points, trop large pour une décision individuelle.




Figure 3 : Régression linéaire Note vs Assiduité avec intervalle de prédiction à 95 %

3.4 Quand l'estimation devient-elle trop incertaine ?

La demi-largeur minimale de l'intervalle de prédiction est de ± 4.44 points (au centre du nuage). Concrètement, pour un élève avec une assiduité inférieure à 72.6 %, la marge d'erreur dépasse ce qui est raisonnable pour une utilisation pédagogique sérieuse.

3.5 Contre-exemples

Nous avons cherché les élèves qui contredisent franchement la tendance. Seuil de résidu : ± 3.36 points.

Élèves assidus mais sous-performants : E103, E028, E024

Élèves peu assidus mais performants : E027, E112, E139, E018, E110, E017, E036, E090, E010

4. QUESTION 3 Y A-T-IL DES PROFILS TYPES D'ELEVES

?

Indépendamment de l'orientation déjà attribuée, le proviseur veut savoir si les données révèlent naturellement des groupes d'élèves aux profils proches.

Choix et justification de la méthode :

Partitionnement : Nous choisissons l'algorithme des K-Means car il est particulièrement performant et adapté pour segmenter des individus sur des variables continues en minimisant la variance intra-classe.

Normalisation : La note (sur 20) et l'assiduité (sur 100) ont des échelles très différentes ; sans traitement, la distance euclidienne serait dominée par l'assiduité.

Nous appliquons donc un StandardScaler (centrage et réduction) pour équilibrer l'importance de chaque variable.

Détermination du nombre de groupes (k) : Nous combinons la méthode du coude (qui cherche le point d'inflexion de l'inertie) et le score de silhouette (qui quantifie la compacité et la séparation des groupes) pour obtenir une décision robuste.

4.1 Combien de groupes ?

Deux méthodes indépendantes convergent : la méthode du coude montre une cassure nette à $k = 2$, et le score de silhouette est maximal à $k = 2$ (score = 0.4764). Nous retenons donc 2 profils types.

4.2 Portrait des profils




Figure 4 : Visualisation des clusters K-Means (note vs assiduité)

Groupe	Description	Proportion	Note moy.	Assiduité moy.
Groupe 1	High-performing, highly attentive	55.3%	13.66/20	94.38%
Groupe 2	Struggling students	44.7%	9.4/20	78.93%

4.3 Cohérence avec l'analyse univariée

Les 8 élèves détectés comme atypiques (Z-score) se répartissent de façon logique dans les deux groupes : les meilleurs dans le groupe performant, les plus faibles dans le groupe en difficulté. C'est un signe de cohérence interne de l'analyse.

4.4 Limites et fragilités de l'analyse

Bien que l'algorithme K-Means apporte une classification robuste et cohérente, cette méthode comporte plusieurs limites dont le proviseur doit être conscient :

Classification stricte ("hard clustering") : L'algorithme K-Means force chaque élève à appartenir à un unique profil. Les élèves situés aux frontières géométriques entre les deux profils (par exemple, des élèves moyennement assidus avec des notes moyennes) sont ainsi classés de manière binaire, ce qui peut masquer le caractère nuancé de leur situation.

Simplification à deux profils : La sélection de $k=2$ sépare la cohorte en deux grands groupes. Cette structure, bien que commode pour des décisions globales, efface la diversité des sous-profils plus spécifiques (élèves performants irréguliers, élèves assidus mais en difficulté).

Dépendance à la normalisation : Les variables ayant des échelles différentes (sur 20 vs. sur 100), une normalisation (StandardScaler) est indispensable. Le regroupement dépend donc directement de cette transformation mathématique préalable.

Sensibilité aux valeurs atypiques : K-Means est sensible aux valeurs extrêmes qui peuvent tirer les centroïdes vers elles et déplacer la frontière de décision, bien que dans notre cas les outliers soient bien intégrés.

5. QUESTION 4 PEUT-ON PREDIRE L'ORIENTATION AUTOMATIQUEMENT ?

Le proviseur voudrait qu'à l'avenir, un système suggère automatiquement une orientation (scientifique ou littéraire) pour un nouvel élève à partir de sa note et de son assiduité.

Choix et justification de la méthode :

- Classification supervisée : Nous comparons deux modèles complémentaires : la Régression Logistique (choisie pour sa simplicité, son interprétabilité et sa capacité à renvoyer des probabilités d'appartenance) et l'Arbre de Décision (choisi pour sa capacité à capturer des relations non linéaires complexes et sa structure visuelle).
- Protocole d'évaluation : Nous utilisons une séparation train/test (70/30) avec stratification afin de préserver la proportion de classes dans les deux échantillons, garantissant une évaluation impartiale.

5.1 Modèles comparés

Régression Logistique : un modèle linéaire, simple, interprétable. Arbre de Décision : un modèle non linéaire, qui peut capturer des interactions complexes. Les données ont été séparées en 70 % d'entraînement et 30 % de test (45 élèves), avec stratification.

5.2 Performances

Métrique	Régression Logistique	Arbre de Décision
Accuracy	73.33%	71.11%
Précision (scientifique)	67.86%	65.52%
Rappel (scientifique)	86.36%	86.36%

Modèle retenu : Régression Logistique (73.33% de bonnes réponses).




Figure 5 : Matrice de confusion Régression Logistique

	Prédit Littéraire	Prédit Scientifique
Réel Littéraire	14	9
Réel Scientifique	3	19

5.3 Analyse des erreurs et préconisations

Sur 45 élèves testés, 12 sont mal classés (26.7%). Dont 9 faux positifs (élèves littéraires classés scientifiques) et 3 faux négatifs (élèves scientifiques classés littéraires).

Toutes les erreurs concernent des élèves dont les caractéristiques se situent dans la zone de recouvrement des deux filières (notes autour de 10-12/20, assiduité entre 75 et 88 %). Autrement dit, là où le modèle se trompe, c'est exactement là où le conseil de classe hésite légitimement.

Préconisations :

- Ne jamais utiliser la prédiction comme unique critère d'orientation.
- Examiner manuellement les cas de désaccord entre le modèle et l'avis des enseignants.
- Réévaluer le modèle chaque année sur les nouvelles cohortes.
- Ajouter d'autres variables à l'avenir (notes par discipline, appréciations).

6. SYNTHÈSE CE QUE TOUT CELA RACONTE

Ces quatre questions ne sont pas indépendantes. Elles forment un parcours cohérent qui, étape par étape, construit une compréhension de plus en plus fine des données :

Q1 - a posé le décor : qui sont les élèves, comment se répartissent leurs notes.

Q2 - a établi le lien entre les deux variables mesurées : l'assiduité influence la note, mais pas suffisamment pour servir de prédicteur fiable.

Q3 - a révélé la structure cachée : deux grands profils d'élèves, qui ne se superposent pas parfaitement à l'orientation administrative.

Q4 - a tenté d'exploiter ces informations pour prédire l'orientation, avec une exactitude de 73 % utile comme outil d'aide, dangereux comme décideur.

Ce que le proviseur doit retenir (en trois phrases)

Les données de votre établissement révèlent une structure claire : les élèves les plus assidus obtiennent les meilleures notes et sont majoritairement en filière scientifique. Un système automatique peut reproduire cette logique avec environ 73 % de réussite, mais il se trompe encore une fois sur quatre et ses erreurs tombent exactement sur les cas les plus difficiles, ceux où l'humain est le plus nécessaire. Utilisez cet outil comme un éclairage complémentaire, pas comme un remplaçant du conseil de classe.

— *Fin du rapport* —